



VERİ BİLİMİ FİNAL PROJESİ

İrem Betül Kocaman

1306240084

1. Problem Tanımı

Bu çalışma kapsamında tanımlanan temel problem, raylı sistem istasyonlarındaki günlük yolcu sayılarının (passenger count) zaman (gün, ay, yıl) ve mekan (hat, istasyon, ilçe) değişkenlerine bağlı olarak ne ölçüde açıklanabileceği ve doğrusal bir modelleme tekniğiyle tahmin edilemeyeceğidir.

Geliştirilen bu analizle aşağıdaki araştırma sorularına yanıt aranmıştır:

- Farklı zaman dilimlerinde (ayın günleri vb.) raylı sistemlerin kullanım yoğunluğu nasıl bir eğilim göstermektedir?
- En yoğun hatlar hangileridir ve bu hatlar üzerindeki aşırı yolcu talepleri ne gibi dağılım karakteristikleri sergilemektedir?
- Zaman ve mekânsal özellikler kullanılarak kurulan çoklu doğrusal regresyon modelinin yolcu sayısını öngörme performansı nedir? Bu özelliklerin tahmine katkıları hangi yöndedir?

2. Kullanılan Veri Seti

Analizde İstanbul Büyükşehir Belediyesi (İBB) / Metro İstanbul bünyesinde oluşan açık veri kaynaklarından elde edilen "2025 Yılı Raylı Sistemler İstasyon Bazlı Yolcu ve Yolculuk Sayıları" (2025-yl-rayl-sistemler-istasyon-bazlı-yolcu-ve-yolculuk-sayilar.csv) veri seti kullanılmıştır.

Satır Sayısı: 135.783 kayıt.

Sütun Sayısı: 11 temel özellik.

3. Yöntem

Keşifçi Veri Analizi (EDA)

Verinin dağılımını anlamak için görselleştirmeler yapılmıştır. Ayın günlerine göre ortalama yolcu sayılarının zamansal davranışı çizgi grafiklerle analiz edilmiştir. Buna ek olarak, toplam yolcu sayısına göre en yoğun 15 hat tespit edilmiş ve bu hatlar içerisindeki varyanslar, medyan yoğunlukları ve ekstrem yoğunluğa ulaşılan uç değer günleri Seaborn kütüphanesi kullanılarak kutu grafikleri ile incelenmiştir.

Modelleme (Lineer Regresyon)

Hedef değişken olan passenger_cnt (Yolcu Sayısı) tahminini gerçekleştirmek üzere Çoklu Doğrusal Regresyon algoritması tercih edilmiştir.

Bağımlı (Hedef) Değişken: passenger_cnt


Sayısal Bağımsız Değişkenler: transaction_day, transaction_month, transaction_year

Kategorik Bağımsız Değişkenler: line, station_name, town


Modellerin eğitilebilmesi adına metin formatındaki kategorik veriler, sayısal vektörlere dönüştürülmüştür (Label Encoding / Feature Encoding yöntemleri ile toplamda 23 hat, 346 istasyon ve 35 ilçe encode edilmiştir).

4. Bulgular


Günlük Ortalama Yolcu:




En çok kullanılan 10 ulaşım hattı:




Yolcu yoğunluğunun ayın günleri ve ilçeler arasındaki ilişkisi:



Farklı hatların yolcu sayıları arasındaki dağılım:



Lineer Regresyon modeli:



5. Sınırlamalar

Lineer regresyon modeli, bağımlı değişken ile bağımsız değişkenler arasında doğrusal bir ilişki varsayar. Ancak yolcu trafiği son derece karmaşık, periyodik dalgalanmaları olan (hafta içi / hafta sonu döngüleri, sabah/akşam işe gidiş-dönüş pikleri) non-lineer (doğrusal olmayan) bir problemdir. R2 değerinin 0.0723 çıkması, sistemin mevcut haliyle lineer mantığa uymadığının istatistiksel kanıtıdır.

6. Öğrenilenler

Karmaşık veriler için doğrusal olmayan modellerin gerekli olduğu anlaşılmıştır. Toplu taşıma yolcu sayıları gibi yüksek sapmalar barındıran kompleks verilerin tahmininde Lineer Regresyon modeli tamamen yetersiz kalmıştır.